TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
ĐẠI HỌC QUỐC GIA TP.HỒ CHÍ MINH

DỰ ĐOÁN GIÁ CÀ PHÊ KẾT HỢP VĂN BẢN ĐA NGUỒN VÀ MÔ HÌNH HÓA BẤT ĐỒNG THÔNG TIN

Môn học: Khai Thác Dữ Liệu và Ứng Dụng (CS313.Q23)

Giảng viên hướng dẫn: TS. Võ Nguyễn Lê Duy

Họ và tên	MSSV	Vai trò
Lương Đắc Nguyên	23521041	Trưởng nhóm, IE & EDA
Nguyễn Thế Luân	23520899	Feature Eng., Mô hình
Đoàn An Minh	23520921	Ground Truth, Web Demo
Hồ Trọng Nghĩa	23521009	Web Demo
Phan Quang Nghĩa	23521017	Pipeline, Slide

TP.Hồ Chí Minh, tháng 5 năm 2026

Tóm tắt nội dung

Báo cáo trình bày hệ thống dự đoán giá cà phê Robusta và Arabica tại thị trường Việt Nam theo hướng kết hợp dữ liệu chuỗi thời gian có cấu trúc với tín hiệu trích xuất từ văn bản báo chí đa nguồn. Chúng tôi thu thập 35.394 bài báo tiếng Việt (03/2023–03/2026), xử lý qua pipeline làm sạch để được 11.769 nguồn, sau đó trích xuất tín hiệu hướng giá bằng hai phương pháp song song: thống kê regex và LLM (DeepSeek V4 Flash). EDA cho thấy `dir_score_lag1` từ LLM đạt r=0,146 với Robusta—gấp ba lần regexd. Thực nghiệm trên bảy phiên bản đặc trưng với sáu mô hình cho kết quả tốt nhất: MAE = 2.025 và Direction Accuracy = 0,767 (Robusta), xác nhận lợi thế của đặc trưng LLM và bài toán mô hình hóa biến động giá. Mã nguồn của dự án được lưu trữ ở https://github.com/DieppDiepp/coffee-price-ie

Chương 1: Giới thiệu

Giá cà phê là thương phẩm nông nghiệp có tính biến động cao, chịu tác động từ điều kiện thời tiết, cung–cầu toàn cầu, tỷ giá hối đoái và tâm lý thị trường. Tại Việt Nam—quốc gia xuất khẩu Robusta lớn nhất thế giới—dự đoán chính xác giá cà phê có ý nghĩa thực tiễn quan trọng với nông dân và doanh nghiệp xuất khẩu.

Nghiên cứu giải quyết hai thách thức chính: (1) thông tin giá từ nhiều nguồn báo chí có thể mâu thuẫn nhau, tạo ra bất đồng thông tin cần được mô hình hóa; (2) trích xuất tín hiệu từ văn bản tiếng Việt đòi hỏi năng lực ngữ nghĩa vượt qua phương pháp đếm từ khóa.

Đóng góp chính: (i) Xây dựng bộ dữ liệu về các nguồn báo giá và bộ dữ liệu mô hình độ bất đồng thông tin; (ii) Xây dựng mô hình dự báo giá; (iii) Kiểm chứng giả thuyết về độ bất đồng thông tin tương quan với giá thực tế; (iv) Xây dựng quy trình trích xuất thông tin từ văn bản bằng phương pháp thống kê truyền thống và bằng LLMs.

Chương 2: Dữ liệu

2.1. Kiến trúc thu thập dữ liệu

Hệ thống sử dụng chiến lược tiếp cận kép: hai luồng dữ liệu độc lập nhưng bổ trợ nhau, được đồng bộ trong giai đoạn ba năm (11/03/2023–11/03/2026). Luồng dữ liệu cấu trúc từ Investing.com cung cấp chuỗi giá OHLCV làm đặc trưng kỹ thuật và Ground Truth. Luồng dữ liệu phi cấu trúc gồm bài báo tiếng Việt thu thập qua Google Search API, làm giàu đặc trưng bằng tín hiệu tâm lý thị trường.

2.2. Dữ liệu cấu trúc và phân tích giá

Dữ liệu giá tách thành hai tập độc lập: Arabica (761 dòng) và Robusta (766 dòng). Mỗi bản ghi gồm bảy trường chuẩn: Date, Price (Close), Open, High, Low,

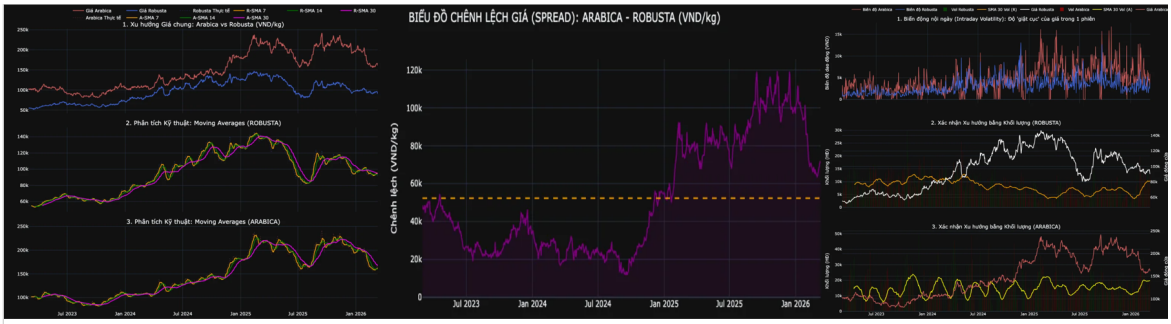

a. SMA b. Spread c. Intraday Volatility

Volume, Change%. Giá đóng cửa là Ground Truth để đối chiếu thông tin báo chí và đánh giá mô hình. Phân chia thời gian: train set 01/03/2023–28/02/2025; test set 01/03/2025–10/03/2026.

Nhóm thực hiện EDA trên chuỗi giá và rút ra ba quan sát: (a) Làm mịn SMA: Áp dụng trung bình động 7, 14, 30 ngày để lọc nhiễu ngắn hạn và làm nổi bật xu hướng dài hạn. (b) Phân tích Spread: Hiệu số giá Arabica–Robusta có tính dừng tốt (dao động ổn định 50.000–60.000 VND/kg); giãn rộng đột ngột gợi ý điểm bất thường thị trường. (c) Biến động nội ngày: Hiệu số High–Low đo phương sai giá; khi biên độ đột biến cao, xác suất thiết lập điểm đổi trạng thái tăng. Khối lượng được dùng làm trọng số lọc tín hiệu giả (giá tăng nhưng volume giảm).

2.3. Dữ liệu phi cấu trúc và Pipeline thu thập

Pipeline hoạt động bốn giai đoạn: (1) Sinh truy vấn liên quan giá cà phê và gọi Search API, thu về 35.394 URL. (2) Crawl nội dung HTML, bóc tách văn bản, loại bỏ quảng cáo và menu. (3) Lọc kỹ thuật: loại liên kết hỏng, anti-bot, trùng lặp (deduplication) theo nội dung. (4) Lọc từ khóa: giữ bài có chứa từ khóa liên quan cà phê. Kết quả: 11.769 văn bản. Lưu ý, dù qua bộ lọc từ khóa vẫn còn nhiễu (bài PR quán nước, bài lịch sử cà phê), đòi hỏi tầng IE tiên tiến hơn ở Chương 4.

Chương 3: Feature Engineering trên dữ liệu giá

3.1. Mục tiêu và chiến lược

Feature Engineering trong chương này đề cập đến quá trình xây dựng thêm đặc trưng từ dữ liệu giá gốc (OHLCV từ Investing.com)—hoàn toàn tách biệt với việc trích xuất thông tin từ văn bản báo chí (trình bày ở Chương 4). Mục tiêu là giúp mô hình khai thác thông tin lịch sử, động lực biến động và tính chu kỳ của thị trường cà phê, thay vì chỉ dùng giá ngày trước.

Đặc trưng được tổ chức thành bốn nhóm: Xu hướng, Biến động, Động lượng và Mùa vụ. Sau khi sinh đặc trưng, nhóm áp dụng lọc theo tương quan với nhãn (`target_price`): giữ đặc trưng có tương quan thuận $\geq 0{,}5$ hoặc tương quan nghịch $\leq -0{,}3$.

3.2. Bốn nhóm đặc trưng kỹ thuật

Bảng 1: Các đặc trưng kỹ thuật sinh từ dữ liệu giá (V2 – Generated Features)

Nhóm	Đặc trưng	Mô tả
Xu hướng	`lag_k` (k=1..5) `rolling_mean_{7,14,30}`	Giá đóng cửa k ngày trước Trung bình trượt, phản ánh xu hướng ngắn–dài hạn

Biến động	`rolling_std_{7,14,30}`
	`boll_upper/lower`
	`hl_spread`
		Độ lệch chuẩn trượt
		Bollinger Bands ($\pm 2\sigma$): rộng = biến động mạnh
		High − Low hàng ngày (biên độ dao động nội ngày)

Động lượng	`return`
	`log_return`
	`momentum_{5,10}`
	`RSI_14`
		Tỉ lệ thay đổi giá so với ngày trước
		Log return, giảm ảnh hưởng biến động cực đoan
		Cường độ thay đổi giá theo cửa sổ thời gian
		Relative Strength Index 14 ngày

Mùa vụ	`dayofweek, month, quarter`
	`dayofyear`
	`month_sin/cos, dow_sin/cos`
		Chỉ số thời gian thô
		Vị trí ngày trong năm
		Mã hóa tuần hoàn giữ tính liên tục chu kỳ

3.3. Nhận xét từ ma trận tương quan

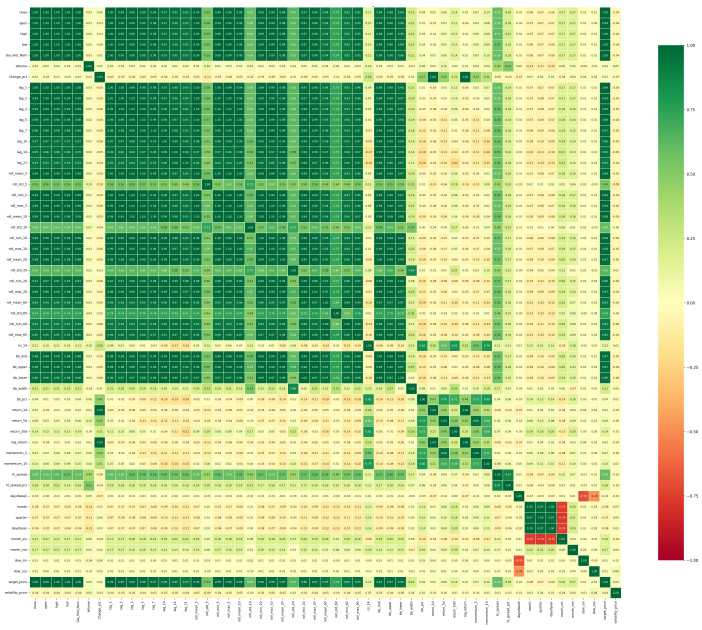

Hình 1: Feature correlation heatmap for Arabica dataset

Như thể hiện trong Hình 1, nhóm đặc trưng xu hướng gồm các biến trễ (`lag_*`) và thống kê trượt (`roll_mean_*`, `roll_min_*`, `roll_max_*`) có tương quan rất

cao với các biến giá ngày tiếp theo, với hệ số tương quan chủ yếu trong khoảng 0.93–1.00, phản ánh tính phụ thuộc thời gian mạnh của chuỗi giá cà phê.

Các đặc trưng biến động như `roll_std_*`, `bb_width` và `hl_spread` có mức tương quan thấp hơn, nhưng bổ sung thông tin về trạng thái biến động thị trường. Các đặc trưng động lượng (`return_*`, `log_return`, `momentum_*`) thể hiện thông tin về tốc độ và xu hướng thay đổi giá. Trong khi đó, các đặc trưng mùa vụ (`month_sin`, `month_cos`, `dow_sin`, `dow_cos`) có tương quan tuyến tính thấp với phần lớn biến khác.

Ngoài ra, ma trận tương quan cho thấy hiện tượng đa cộng tuyến đáng kể giữa các đặc trưng cùng nhóm, đặc biệt ở nhóm biến trễ và rolling statistics với hệ số tương quan thường lớn hơn 0.95, cho thấy sự dư thừa thông tin và tạo động lực cho bước lựa chọn đặc trưng. Các đặc trưng này có mức tương quan thấp với nhãn `volatility_price`, cho thấy khả năng đóng góp thông tin tuyến tính còn hạn chế.

Chương 4: Trích xuất thông tin từ văn bản (IE)

Chương này trình bày quá trình trích xuất đặc trưng từ văn bản báo chí—hoàn toàn khác với Feature Engineering ở Chương 3. Nguồn đầu vào là 11.769 bài báo thu thập ở Chương 2. Hai pipeline IE được xây dựng song song và tạo ra hai tập đặc trưng độc lập: V3.1 và V3.2.

4.1. Pipeline thống kê truyền thống (V3.1)

Pipeline xử lý TITLE+SNIPPET từ Search API bằng biểu thức chính quy để phát hiện từ khóa tăng/giảm (“cao hơn”, “lao dốc”,...) và trích xuất giá bằng pattern VND, có lọc trong khoảng giá phù hợp từ 30.000 đến 250.000 VND.

Kết quả được tổng hợp theo ngày thành các đặc trưng: điểm sentiment `dir_score_ts_d`, tỉ lệ bài UP/DOWN, độ bất đồng ý kiến (`dir_entropy`), và hệ số biến thiên giá (`price_cv`). Cross-check giữa TITLE+SNIPPET và CONTENT HTML đạt $r \approx 0{,}6$ ($p < 10^{-100}$), xác nhận chất lượng tín hiệu là có, nhưng chưa quá tốt, cần dùng LLMs để đọc hiểu nội dung văn bản tốt hơn.

4.2. Pipeline LLM (V3.2)

Để tối ưu ngữ cảnh đầu vào và giảm chi phí token, văn bản thô trước tiên đi qua bước phân rã và xếp hạng đoạn văn (paragraph ranking). Hệ thống lọc bỏ thông tin nhiễu (quảng cáo, điều hướng), sau đó chấm điểm các đoạn văn dựa trên trọng số từ khóa (giá tiền, loại cà phê, địa phương) để trích xuất các range paragraph giàu thông tin thống kê nhất.

Phần văn bản đã lọc này được đưa vào DeepSeek V4 Flash để phân loại theo bốn nhãn ngữ nghĩa (UP/DOWN/STABLE/MIXED) kèm điểm certainty (1

= GIÁ THỰC TẾ đến 5 = KHÔNG CÓ GIÁ). Prompt yêu cầu trả về JSON gồm sáu trường: `is_coffee_price`, `direction`, `price_vnd`, `price_region`, `certainty`, `reasoning`.

Tầng lọc `is_coffee_price` giúp loại bỏ 25–38% bài không thực sự chứa thông tin giá—lợi thế vượt trội so với regex. Kết quả cho thấy trung bình các bài được giữ lại đạt độ tin cậy cao với certainty ≤ 1.53 (đa phần giá được khẳng định chính xác trong bài).

Bảng 2: Đặc trưng văn bản sau tổng hợp theo ngày (V3.1 và V3.2)

Phiên bản	Đặc trưng	Mô tả
V3.1	`dir_score_ts_d_lag1/roll3`	Điểm sentiment tổng hợp (hôm qua và trượt 3 ngày)
(Truyền thống)	`pct_tang/giam_d_lag1`	Tỉ lệ bài dự báo tăng/giảm hôm qua
	`dir_entropy_d`	Mức bất đồng ý kiến
	`price_cv_ts_d_lag1`	Hệ số biến thiên giá được đề cập hôm qua
	`n_articles_d_lag1`	Số lượng bài báo hôm qua
	`SIG_BULLISH/BEARISH`	Tín hiệu thị trường (Tăng/Giảm)
	`SIG_LOW_DISAGR`	Tín hiệu mức độ bất đồng thấp
	`SIG_HIGH_ENTROPY`	Tín hiệu mức độ bất đồng cao
	`SIG_CONFIDENT_DISAGR`	Tín hiệu bất đồng có độ tin cậy cao
V3.2	`dir_score_ts_d_lag1/roll3`	Điểm sentiment LLM (hôm qua và trượt 3 ngày)
(LLM)	`pct_tang/giam_d_lag1`	Tỉ lệ bài dự báo tăng/giảm LLM hôm qua
	`dir_entropy_d`	Mức bất đồng ý kiến LLM
	`price_cv_ts_d_lag1`	Hệ số biến thiên giá được đề cập (LLM)
	`n_articles_d_lag1`	Số lượng bài báo hôm qua
	`SIG_BULLISH/BEARISH`	Tín hiệu thị trường LLM (Tăng/Giảm)
	`SIG_HIGH_ENTROPY`	Tín hiệu mức độ bất đồng cao LLM
	`SIG_HIGH_CONFIDENCE`	Tín hiệu LLM có độ tin cậy cao

4.3. Phân tích EDA – So sánh tương quan hai pipeline

Hình 2 so sánh tương quan Pearson của đặc trưng văn bản hai pipeline với return giá ngày hôm sau.

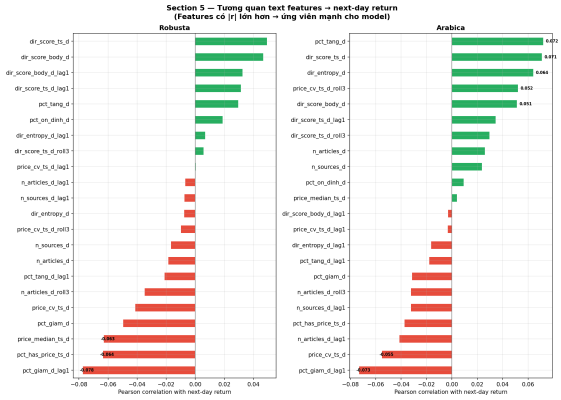

(a) Pipeline regex (V3.1)

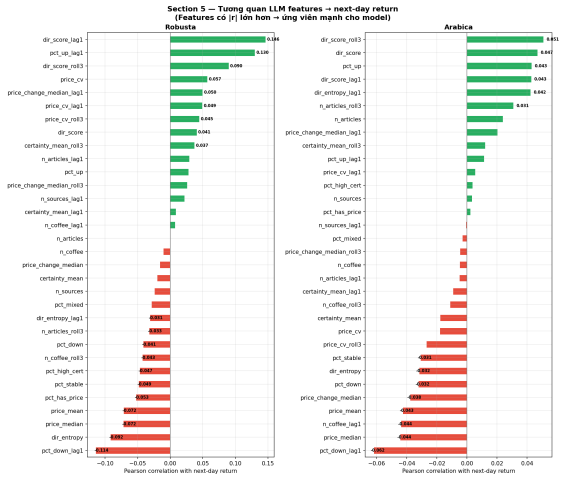

(b) Pipeline LLM (V3.2)

Hình 2: Tương quan Pearson giữa đặc trưng văn bản và return ngày sau (Robusta và Arabica)

`dir_score_lag1` LLM đạt $r{=}{+}0{,}146$ cho Robusta, gấp ba lần regex (`pct_giam_d_lag1`, $r{=}{-}0{,}078$). Phân loại ngữ nghĩa UP/DOWN/STABLE/MIXED thay vì đếm từ khóa giải thích sự vượt trội này. Lag1 là độ trễ tối ưu; same-day (lag0) có rủi ro data leakage.

Chương 5: Thực nghiệm

5.1. Cấu hình phiên bản đặc trưng

Bảng 3 mô tả bảy phiên bản đặc trưng được thiết kế theo nguyên tắc tích lũy từng thành phần, cho phép đánh giá đóng góp biên của từng loại đặc trưng. Các đặc trưng ở V2 và V3.x được lọc theo tương quan với nhãn (thuận $\geq 0{,}5$ hoặc nghịch $\leq -0{,}3$), ngoại trừ V4.1 và V4.2 dùng toàn bộ đặc trưng văn bản để đánh giá ảnh hưởng của việc lọc.

Bảng 3: Bảy phiên bản đặc trưng thực nghiệm

Version	Bài toán	Cấu hình đặc trưng
V1	Dự đoán giá ngày sau	Original Features (OHLCV gốc)
V2	Dự đoán giá ngày sau	Original + Selected Generated Features
V3.1	Dự đoán giá ngày sau	Original + Selected Traditional Features
V3.2	Dự đoán giá ngày sau	Original + Selected LLM Features
V4.1	Dự đoán giá ngày sau	Original + Generated + ALL Traditional Features
V4.2	Dự đoán giá ngày sau	Original + Generated + ALL LLM Features
V5	Dự đoán biến động	Original Features (bài toán tái định nghĩa)

5.2. Thiết lập thực nghiệm

Sáu mô hình được đánh giá: XGBoost, LightGBM, LASSO, Ridge, ElasticNet, SVR. Dữ liệu phân chia theo thứ tự thời gian: train set (01/03/2023–28/02/2025) và test set (01/03/2025–10/03/2026). Tham số tối ưu qua GridSearch kết hợp Time Series Cross-Validation (5 folds trượt). Hai độ đo đánh giá: MAE và Directional Accuracy (DA).

5.3. Kết quả

Bảng 4: Kết quả MAE trên bộ dữ liệu Arabica

Model	V1	V2	V3.1	V3.2	V4.1	V4.2	V5
SVR	3970.1356	6968.5032	3958.6918	17943.0788	10289.8655	9423.4618	3974.0514
LASSO	3893.7748	4239.7658	4051.9363	4413.0245	5002.0946	10514.0485	3895.0363
ElasticNet	3896.1806	4486.6515	4055.6797	4386.4662	4987.0273	10515.2696	3869.3039
Ridge	3895.8804	4382.6054	4052.1270	4396.8514	4890.8851	9529.9494	3888.0806
LightGBM	5947.6382	13288.5731	6351.8573	30213.6398	14520.4866	39374.5480	3918.5783
XGBoost	5090.7871	8837.6400	5108.2307	6276.3014	10440.6209	18618.7410	3840.9382

Bảng 5: Kết quả MAE trên bộ dữ liệu Robusta

Model	V1	V2	V3.1	V3.2	V4.1	V4.2	V5
SVR	2053.7040	2652.9279	2190.0492	2355.3025	3201.1475	4848.6685	2135.9304
LASSO	2197.0123	2427.6923	2235.2739	2045.4723	3219.6503	2985.9747	2197.6227
ElasticNet	2217.5119	2361.5613	2238.6791	2033.3917	2439.4049	3375.6002	2133.7203
Ridge	2225.5964	2390.6144	2257.5324	2024.9996	2715.1039	4838.1945	2145.1897
LightGBM	2594.1140	3460.5296	2709.8033	2983.7501	2964.1708	18536.2639	2177.9287
XGBoost	2642.3774	2987.2300	2692.9510	2643.8632	2880.7440	5545.0204	2144.6701

Bảng 6: Kết quả Directional Accuracy trên bộ dữ liệu Arabica

Model	V1	V2	V3.1	V3.2	V4.1	V4.2	V5
SVR	0.5391	0.5000	0.5430	0.5150	0.5659	0.5733	0.7148
LASSO	0.5039	0.4961	0.5000	0.5210	0.5220	0.5200	0.7422
ElasticNet	0.5273	0.5078	0.5078	0.5749	0.5756	0.5200	0.7500
Ridge	0.5039	0.5117	0.5117	0.5449	0.5073	0.5733	0.7539
LightGBM	0.5078	0.5195	0.5000	0.5210	0.5561	0.5200	0.7305
XGBoost	0.4727	0.5625	0.4883	0.5629	0.5317	0.5067	0.7148

Bảng 7: Kết quả Directional Accuracy trên bộ dữ liệu Robusta

Model	V1	V2	V3.1	V3.2	V4.1	V4.2	V5
SVR	0.5736	0.4961	0.5116	0.5376	0.5374	0.5781	0.7636
LASSO	0.4147	0.4341	0.4845	0.5723	0.5234	0.5469	0.7597
ElasticNet	0.3992	0.4845	0.4806	0.5896	0.5748	0.6563	0.7597
Ridge	0.3992	0.4535	0.4922	0.5838	0.5374	0.5469	0.7597
LightGBM	0.5078	0.4884	0.4961	0.5491	0.5327	0.5156	0.7519
XGBoost	0.4767	0.5233	0.5039	0.5838	0.5561	0.5469	0.7674

5.4. Phân tích kết quả

5.4.1. Hiệu quả của đặc trưng LLM (V3.2)

Như thể hiện trong Bảng 5, việc bổ sung và lựa chọn đặc trưng LLM giúp cải thiện hiệu quả dự đoán trên một số cấu hình mô hình. Trên bộ dữ liệu Robusta, V3.2 đạt MAE thấp nhất (2024.9996 - Ridge), thấp hơn V1 (2197.01 - Lasso), V2 (2361.56 - ElasticNet) và V3.1 (2238.68 - ElasticNet). Đồng thời, V4.2 sử dụng toàn bộ đặc trưng LLM không qua bước lọc đạt MAE cao hơn đáng kể so với V3.2, cho thấy bước lựa chọn đặc trưng giúp giảm nhiễu và loại bỏ thông tin dư thừa. Xu hướng tương tự cũng xuất hiện với đặc trưng truyền thống khi V4.1 đạt MAE cao hơn V3.1 (2439.40 so với 2238.68 - ElasticNet).

5.4.2. Lợi thế của bài toán dự đoán biến động (V5)

Khi các mô hình được huấn luyện trên dữ liệu V5 đạt MAE cạnh tranh trên cả hai bộ dữ liệu. Cụ thể, V5 đạt MAE là 2133.72 - ElasticNet trên Robusta và 3840.94 - XGBoost trên Arabica, thấp hơn hoặc tương đương phần lớn các cấu hình V1–V4. Điều này cho thấy việc chuyển từ dự đoán giá tuyệt đối sang bài toán dự đoán biến động có khả năng hỗ trợ mô hình học tốt hơn cấu trúc thay đổi của thị trường.

5.4.3. Robusta vs Arabica

Dựa trên Bảng 5 và Bảng 4, các mô hình trên Robusta nhìn chung đạt MAE thấp hơn so với Arabica. Kết quả này phù hợp với phân tích EDA trước đó khi đặc trưng LLM trên Robusta thể hiện mức tương quan cao hơn ($r = 0.146$) so với Arabica ($r \approx 0.06$), cho thấy tín hiệu ngôn ngữ có thể mang nhiều thông tin hơn đối với thị trường Robusta.

5.4.4. Phân tích kết quả Directional Accuracy

Bảng 6 và Bảng 7 cho thấy V5 đạt Directional Accuracy (DA) cao nhất trên cả hai thị trường, với giá trị khoảng 0.71–0.75 trên Arabica và 0.75–0.77 trên Robusta. Kết quả này cho thấy bài toán dự đoán biến động phù hợp hơn trong việc nắm bắt xu hướng thay đổi của thị trường so với dự đoán trực tiếp giá trị tuyệt đối. Ngoài ra, việc bổ sung đặc trưng LLM (V3.2) nhìn chung cải thiện DA, đặc biệt trên Robusta, cho thấy tín hiệu ngôn ngữ mang lại nhiều thông tin hữu ích hơn đối với thị trường này.

5.5. Phân tích hiện tượng độ trễ dự đoán

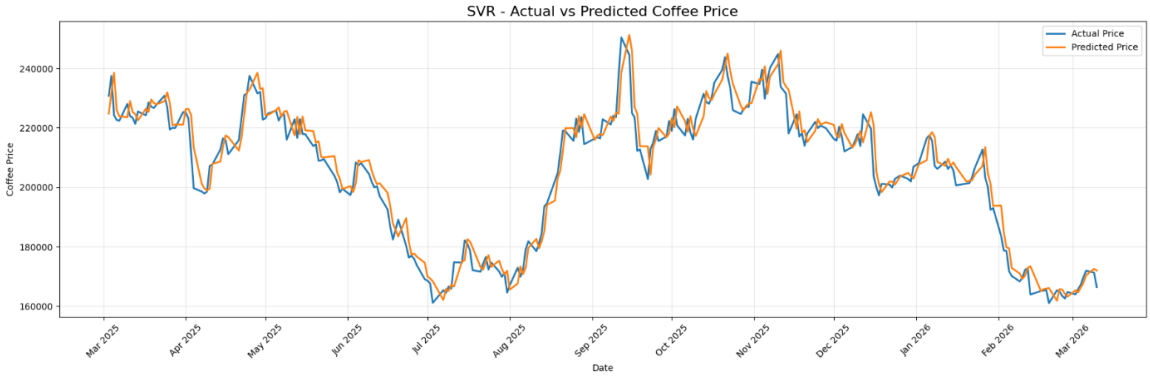

Hình 3: Kết quả dự đoán giá cà phê Arabica của mô hình SVR

Hình 3 cho thấy mô hình SVR bám khá sát xu hướng biến động của giá Arabica và tái hiện được các pha tăng giảm chính của thị trường, phù hợp với kết quả MAE thấp trên tập kiểm tra. Tuy nhiên, mô hình xuất hiện hiện tượng prediction lag, khi đường dự đoán phản ứng chậm hơn so với giá thực tế, đặc biệt tại các điểm đảo chiều hoặc biến động mạnh (ví dụ khoảng tháng 9/2025 và đầu năm 2026). Hiện tượng này có thể xuất phát từ xu hướng làm trơn (smoothing effect) của SVR, khiến mô hình khó nắm bắt các biến động ngắn hạn hoặc các cú sốc thị trường.

5.5.1. Mô hình tốt nhất trên từng thị trường

Tổng hợp kết quả trong các bảng MAE cho thấy hiệu quả mô hình khác nhau giữa hai thị trường. Trên Robusta, kết quả tốt nhất đạt được bởi Ridge sử dụng cấu hình V3.2 với MAE bằng 2024.9996, cho thấy việc kết hợp đặc trưng LLM đã qua lựa chọn với mô hình tuyến tính mang lại hiệu quả đáng kể. Trong khi đó, trên Arabica, XGBoost sử dụng V5 đạt kết quả tốt nhất với MAE bằng 3840.94, cho thấy bài toán dự đoán biến động phù hợp hơn đối với đặc điểm của thị trường này.